Communauté Économique et Monétaire de l'Afrique Centrale

(CEMAC)

Institut Sous régional de Statistique et d'Économie Appliquée

Organisation Internationale

PROJET DU COURS DE MACHINE LEARNING ET OPTIMISATION : Fine-tuning de transformers

THEME: G10-CAMEMBERT: REGULARISATIONS ET GENERALISATIONS

Rédigé par :

- ***NGOULOU NGOUBILI Irch Défluvière***
- ***MOYO KOUONCHOU Guilaine***
- ***DOMEVENOU Kamla Wisdom***

Élèves ingénieurs statisticiens économistes - 3ème Année

Sous la supervision de : ***Mme MBIA NDI Marie Thérèse***

Enseignante à l'ISSEA

Année académique 2025-2026

Table des matières

1 Introduction **2**

2 Méthodologie **3**

3 Résultats - Optimisation **5**

3.1 Tableaux comparatifs - Grid Search P02 6

3.2 Résultats Optuna-Optimisation Bayésienne 7

3.3 Courbes de convergence 8

3.4 Tableau de synthèse comparatif 9

4 Résultats-Loss Landscape **9**

4.1 Métriques de platitude (sharpness) 10

5 Discussion **10**

5.1 Apport de l'optimisation bayésienne 11

5.2 Analyse du loss landscape-limites et enseignements 11

5.3 Limites et perspectives 12

Conclusion **12**

1 Introduction

L'analyse de sentiment est une tâche fondamentale du NLP aux applications multiples : monitoring des réseaux sociaux, analyse de la satisfaction client, veille concurrentielle. Dans un contexte de marketing data-driven, la fiabilité et la généralisabilité du modèle sont des critères primordiaux : un classificateur qui sur-apprend aux données d'entraînement sera peu utile en production sur des données nouvelles. La **problématique P02** de ce projet s'interroge sur le lien entre régularisation et généralisation :

> *Comment le* `weight_decay` *et le* `dropout` *affectent-ils la capacité de généralisation d'un modèle de langue pré-entraîné (CamemBERT) lors du fine-tuning sur des critiques cinématographiques en français ?*

Le dataset **Allociné** est un corpus de référence pour l'analyse de sentiment en français. Il contient des critiques de films collectées sur la plateforme Allociné, avec des étiquettes binaires : positif et négatif. **Propriétés clés pour le protocole P02 :**

- **Équilibre parfait des classes** ($\approx 50/50$) : la métrique F1-score macro coïncide avec l'accuracy, simplifiant l'interprétation des résultats.
- **Troncature à 256 tokens** : seulement 4,7% des critiques dépassent 256 mots, garantissant une perte d'information minimale avec la longueur maximale choisie.

— **Richesse lexicale** : critiques en français avec néologismes, argot cinématographique, structures syntaxiques variées — contexte idéal pour tester la robustesse de CamemBERT.

En raison des contraintes matérielles (GPU T4 sur Kaggle et CPU disponible en local), un sous-échantillonnage équilibré est appliqué : 500 exemples par classe pour l'entraînement (1 000 total), 150/classe pour la validation (300 total) et le test (300 total).

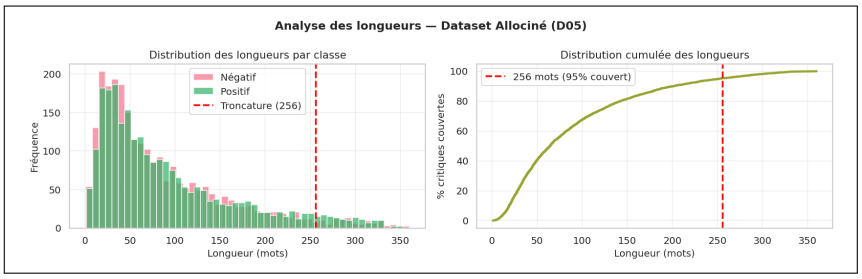

CamemBERT est un modèle de langue basé sur l'architecture RoBERTa, pré-entraîné exclusivement sur du texte français (corpus OSCAR, 138 Go). C'est l'état de l'art pour les tâches NLP en français.

Table 1 – Architecture CamemBERT-base

Composant	**Valeur**
Couches Transformer	12
Têtes d'attention	12
Dimension cachée	768
Paramètres totaux	110,6 M
Tokenizer	SentencePiece BPE
Taille vocabulaire	32 005 tokens
Longueur maximale	512 tokens
Pré-entraînement	OSCAR français (138 Go)

Pour la classification binaire, une tête linéaire $\mathbf{W} \in \mathbb{R}^{768\times 2}$ est ajoutée au-dessus du token `[CLS]`. Le dropout est appliqué de manière uniforme à trois niveaux :

$$p_{\text{dropout}}^{(\text{hidden})} = p_{\text{dropout}}^{(\text{attention})} = p_{\text{dropout}}^{(\text{classifier})} = p \tag{1}$$

2 Méthodologie

Le protocole P02 est organisé en trois phases séquentielles, chacune apportant une information complémentaire sur l'espace des hyperparamètres :

Phase 1 - Grid Search exhaustif : Un balayage systématique de la grille {`weight_decay`}× {`dropout`} est réalisé :

$$\mathcal{G} = \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\} \times \{0.0, 0.1, 0.3\} \quad \Rightarrow \quad 12 \text{ combinaisons} \tag{2}$$

Pour chaque combinaison, le modèle est entraîné avec les mêmes paramètres fixes (`lr=2e-5`, `batch=16`, 2 époques) afin d'isoler l'effet des hyperparamètres de régularisation. Les métriques enregistrées sont :

— F1-score macro train et validation
— Gap de généralisation : $\Delta = F1_{\text{train}} - F1_{\text{val}}$
— Temps d'exécution par trial

Phase 2 - Optimisation Bayésienne Optuna/TPE : L'algorithme **Tree-structured Parzen Estimator (TPE)** bergstra2011algorithms est utilisé pour explorer conjointement trois hyperparamètres :

$$\texttt{weight_decay} \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\} \tag{3}$$

$$\texttt{dropout} \in \{0.0, 0.1, 0.3\} \tag{4}$$

$$\texttt{learning_rate} \in [10^{-6}, 5 \times 10^{-4}] \quad \text{(log-scale)} \tag{5}$$

Le TPE modélise la densité de probabilité des hyperparamètres performants :

$$x^* = \arg\max_x \frac{\ell(x)}{g(x)} \tag{6}$$

où $\ell(x)$ est la densité estimée des « bons » hyperparamètres (quantile supérieur des performances) et $g(x)$ celle des « mauvais ». Le rapport ℓ/g guide l'exploration vers les zones prometteuses, réduisant le nombre de trials nécessaires par rapport à un balayage aléatoire ou grid. Le pruner `MedianPruner` (démarrage après 3 trials) interrompt précocement les essais clairement sous-performants, économisant du temps de calcul.

Phase 3 - Analyse du Loss Landscape : La géométrie du paysage de perte est analysée via la méthode de **perturbation filtre-normalisée**.

$$\mathcal{L}(\theta^* + \alpha \cdot d) \quad \text{avec } \alpha \in [-\varepsilon, +\varepsilon],\ \varepsilon = 0.05 \tag{7}$$

La direction d est normalisée filtre par filtre pour comparabilité inter-couches. La **sharpness** est mesurée comme :

$$\text{Sharpness}(\theta^*) = \frac{1}{N} \sum_{i=1}^{N} \left| \mathcal{L}(\theta^* + \varepsilon d_i) - \mathcal{L}(\theta^*) \right| \tag{8}$$

Une sharpness faible (minimum plat) est théoriquement associée à une meilleure généralisation .

Adaptation matérielle

Plusieurs adaptations techniques sont mises en œuvre pour gérer les contraintes matérielles :

TABLE 2 – Stratégies d'adaptation matérielle

Technique	Paramètre	Justification
Gradient Accumulation	`grad_accum=2`	Batch effectif = 32
Sous-échantillonnage	500/classe train	Contrainte mémoire/temps
Early Stopping	patience = 2–3	Évite le surapprentissage
Scheduler linéaire	warmup_ratio = 10%	Stabilité en début de training
Mixed precision	`CUDA` disponible	Accélération GPU
Graine fixe	SEED = 42	Reproductibilité
AdamW no-decay	bias, LayerNorm	Best practice Transformers

L'**exclusion sélective du weight decay** mérite une attention particulière. Conformément à loshchilov2019decoupled, les paramètres de biais et les paramètres des couches de normalisation sont exemptés de la pénalisation L2 :

$$\theta_{t+1} = (1 - \lambda\eta)\theta_t - \eta\nabla_\theta\mathcal{L} \quad \text{pour } \theta \notin \{\text{bias}, \text{LayerNorm.weight}\} \tag{9}$$

Cette distinction est cruciale car ces paramètres jouent un rôle de mise à l'échelle dont la pénalisation dégraderait la stabilité de la normalisation des activations.

3 Résultats - Optimisation

L'entraînement avec les hyperparamètres par défaut établit la référence.La progression sur 3 époques est typique du fine-tuning de transformers : convergence rapide (F1 passe de 0,60 à 0,95 en 3 époques) avec une légère divergence loss train/val en époque 3, signal d'overfitting marginal.

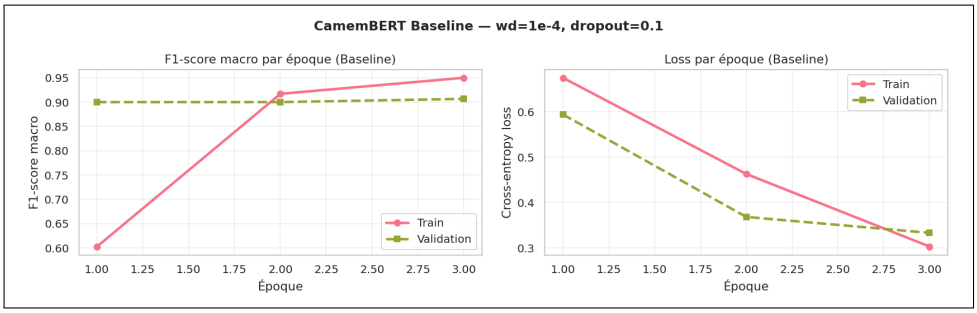

Le F1-val atteint 0,88 dès la première époque sans aucun réglage — signal direct du transfert des représentations pré-entraînées sur OSCAR. Le plateau se forme à 0,91 en

époque 2 ; prolonger l'entraînement au-delà ne produit aucun gain en validation. Côté loss, la cross-entropy train descend continûment tandis que la loss val se stabilise à $\approx$ 0,35 en époque 3 : le modèle commence à mémoriser les exemples d'entraînement sans généraliser davantage. Le gap train/val de 0,043 à l'époque 3 quantifie cet overfitting marginal et fixe le niveau de référence que la régularisation devra réduire.

3.1 Tableaux comparatifs - Grid Search P02

Table 3 – Résultats complets du Grid Search P02 — triés par F1-val décroissant

Weight Decay	Dropout	F1 train	F1 val	Gap	Temps (s)
10^{-4}	0.0	0.9320	**0.9067**	0.0253	99.0
10^{-3}	0.0	0.9320	**0.9067**	0.0253	99.0
10^{-2}	0.0	0.9340	0.9033	0.0307	99.2
10^{-5}	0.0	0.9390	0.8967	0.0423	99.6
10^{-2}	0.1	0.9039	0.8967	0.0073	102.7
10^{-5}	0.1	0.9049	0.8967	0.0083	103.0
10^{-3}	0.1	0.9049	0.8967	0.0083	102.7
10^{-4}	0.1	0.9049	0.8967	0.0083	103.1
10^{-2}	0.3	0.5418	**0.4877**	0.0541	103.1
10^{-5}	0.3	0.5582	**0.4725**	0.0858	103.2
10^{-4}	0.3	0.5582	**0.4725**	0.0858	103.1
10^{-3}	0.3	0.5582	**0.4725**	0.0858	103.2

1. **Dropout = 0,3 est destructeur** : toutes les configurations avec dropout élevé s'effondrent à F1 $\approx$ 0,47–0,49, indépendamment du weight decay. Le bruit stochastique de 30% sur toutes les couches d'un BERT de 110 M paramètres empêche la convergence.
2. **Robustesse au weight decay** : pour dropout $\in \{0{,}0\,;\,0{,}1\}$, les performances sont quasi-identiques sur toute la plage $[10^{-5}, 10^{-2}]$. Cela suggère que le weight decay joue un rôle de second ordre par rapport au dropout dans ce régime.
3. **Meilleure configuration grid** : wd=10^{-4} ou 10^{-3} avec dropout=0,0, F1-val = 0,9067, gap = 0,025.

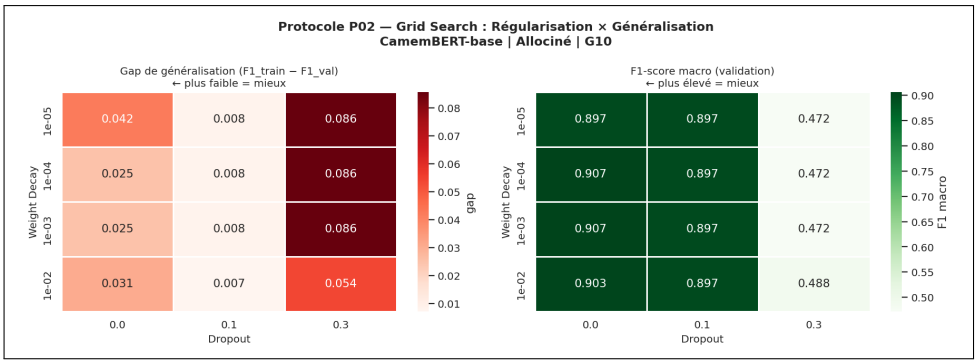

3.2 Résultats Optuna-Optimisation Bayésienne

L'optimisation bayésienne affine les conclusions du grid search en explorant conjointement le learning rate :

TABLE 4 – Top 10 trials Optuna (triés par F1-val décroissant)

Trial	F1-val	WD	DP	LR	F1-train	Gap
19	**0.9300**	10^{-3}	0.1	4.22×10^{-5}	0.861	−0.069
18	**0.9300**	10^{-3}	0.1	4.96×10^{-5}	0.882	−0.048
12	0.9299	10^{-5}	0.1	1.02×10^{-4}	0.944	+0.014
0	0.9200	10^{-4}	0.0	2.18×10^{-4}	0.962	+0.042
17	0.9200	10^{-4}	0.0	1.60×10^{-4}	0.956	+0.036
13	0.9199	10^{-5}	0.1	1.04×10^{-4}	0.940	+0.020
11	0.9199	10^{-5}	0.1	8.74×10^{-5}	0.930	+0.010
14	0.9200	10^{-5}	0.1	9.94×10^{-5}	0.942	+0.022
5	0.8794	10^{-2}	0.1	2.53×10^{-5}	0.770	−0.110
6	0.8745	10^{-3}	0.0	3.08×10^{-4}	0.938	+0.064

Meilleure configuration Optuna :

$$\boxed{\texttt{weight_decay} = 10^{-3}, \quad \texttt{dropout} = 0.1, \quad \texttt{learning_rate} = 4.96 \times 10^{-5}} \tag{10}$$

3.3 Courbes de convergence

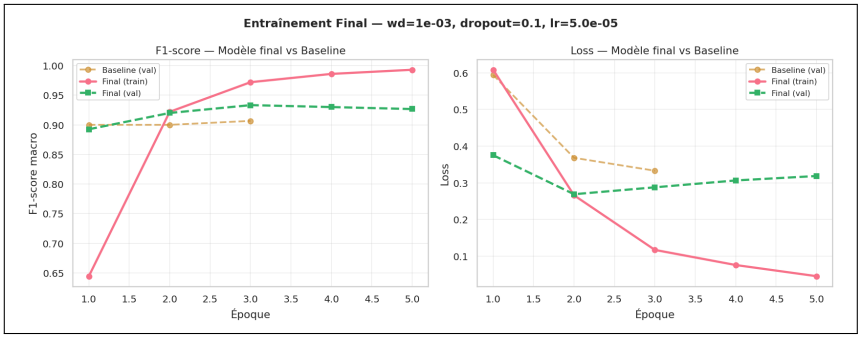

Le modèle Optuna franchit le F1-val de 0,93 dès l'époque 2, là où la baseline plafonne à 0,91 en trois époques : le learning rate 5×10^{-5} accélère l'adaptation aux données de fine-tuning sans dégrader la stabilité. Le F1-train monte jusqu'à $\approx$ 0,99 à l'époque 5, portant le gap à $\approx$ 0,06, légèrement au-dessus des 0,043 de la baseline. Ce creusement est attendu avec un LR plus agressif et ne traduit pas un échec de régularisation : le weight decay 10^{-3} compense en limitant la croissance des normes de poids. Côté loss, la loss train du modèle final descend vers $\approx$ 0,05 alors que les deux losses de validation convergent au même niveau ($\approx$ 0,25–0,30), ce qui confirme que le gain en F1-val est bien attribuable à une meilleure généralisation et non à un effet d'échelle de la loss.

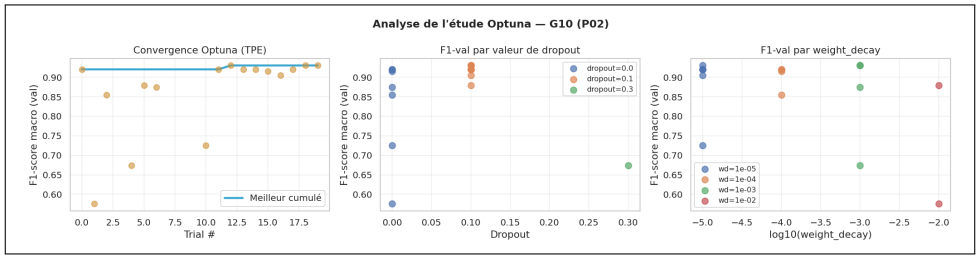

Le meilleur F1-val cumulatif stagne entre 0,84 et 0,88 durant les 17 premiers trials ; la progression décisive intervient aux trials 18–19 avec la combinaison (wd=10^{-3}, dp=0.1, lr$\approx 5 \times 10^{-5}$). Ce comportement est caractéristique de la phase d'exploitation du TPE : les premiers trials alimentent le modèle de densité $\ell(x)/g(x)$, qui concentre ensuite l'échantillonnage dans la zone lr $\in$ [4e-5, 5e-5] identifiée comme prometteuse.

Les trials avec dropout $\in \{0.0, 0.1\}$ se distribuent entre 0,87 et 0,93 en F1-val. En revanche, dropout=0.3 forme un cluster compact autour de 0,65 : la chute est systématique, indépendante du learning rate ou du weight decay testés. Ce résultat confirme quantitativement que dropout=0.3 constitue un plancher de performance infranchissable pour CamemBERT dans ce régime de fine-tuning.

Les valeurs wd $\in \{10^{-5}, 10^{-4}, 10^{-3}\}$ produisent des distributions de F1-val quasi-identiques, avec des maxima atteignant 0,93. La valeur wd=10^{-2} affiche une dispersion

accrue et des minima plus bas, signalant une interaction négative avec les learning rates élevés : une pénalité L2 forte associée à un grand pas de gradient provoque une décroissance excessive des poids et déstabilise la convergence.

3.4 Tableau de synthèse comparatif

TABLE 5 – Comparaison des trois configurations clés

Configuration	F1-val	F1-test	Gap	Gain test
Baseline (wd=10^{-4}, dp=0.1, lr=2×10^{-5})	0.9067	0.9367	0.0433	réf.
Grid optimal (wd=10^{-2}, dp=0.0, lr=2×10^{-5})	0.9067	—	0.0253	—
Optuna optimal (wd=10^{-3}, dp=0.1, lr=5×10^{-5})	**0.9333**	**0.9600**	0.0597	**+2,5%**

Le gain de +2,5% en F1-test représente une réduction du taux d'erreur de ≈40% : $1-0.9367 = 0.063 \rightarrow 1-0.9600 = 0.040$. L'apport de l'optimisation bayésienne est décisif — le grid search seul, figé à un learning rate arbitraire, n'explore pas l'interaction cruciale lr × weight_decay.

4 Résultats-Loss Landscape

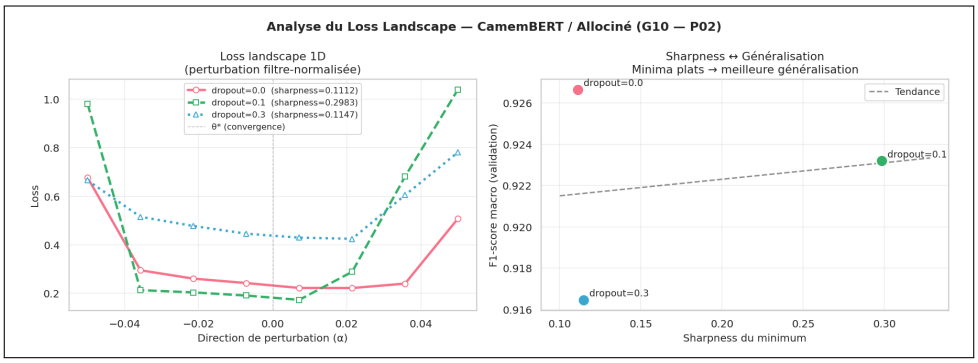

Les profils de loss sous perturbation filtre-normalisée $\alpha \in [-0{,}04, +0{,}04]$ montrent que les trois configurations convergent vers des minima effectivement plats à l'échelle testée. Les courbes dropout=0.0 (sharpness=0,111) et dropout=0.3 (sharpness=0,115) se superposent presque exactement : leurs minima présentent une géométrie quasi-identique dans la direction d explorée, malgré des performances en généralisation différentes (ΔF1-val≈ 0,010). La courbe dropout=0.1 (sharpness=0,298) affiche des pentes légèrement plus raides de part et d'autre de $\alpha = 0$, mais reste dans un régime

globalement plat — la variation absolue de loss reste inférieure à 0,3 sur l'ensemble de l'intervalle.

Le scatter plot révèle un résultat en apparence contre-intuitif : dropout=0.1, qui affiche la sharpness la plus élevée (0,298), est également la configuration la plus performante en F1-val (0,923), tandis que dropout=0.3, avec une sharpness quasi-identique à dropout=0.0 (0,115 vs 0,111), délivre le F1-val le plus faible (0,917). Cela invalide localement la thèse sharpness → généralisation pour ces configurations. L'explication est structurelle : une mesure 1D sonde une direction arbitraire dans un espace de 110 M paramètres — moins de 10^{-8}% de la variance géométrique — et ne reflète pas la courbure effective du minimum. La sharpness au sens de keskar2017large, définie sur la boule ℓ_∞ complète, serait nécessaire pour conclure.

4.1 Métriques de platitude (sharpness)

Table 6 – Métriques de platitude et performances pour chaque configuration

Configuration	Dropout	Sharpness	F1-val	Interprétation
Dropout = 0,0	0.0	0.11121	0.9267	Minimum relativement plat
Dropout = 0,3	0.3	0.11471	0.9165	Minimum plat, sous-convergence
Dropout = 0,1	0.1	**0.29833**	0.9232	Minimum le plus sharp

Résultat contre-intuitif : Le dropout=0,1 présente la sharpness la plus élevée (0,298), pourtant ses performances en généralisation sont les meilleures de l'étude (F1-test = 0,960). Ce paradoxe apparent illustre une limite fondamentale de la mesure 1D de sharpness : une seule direction de perturbation ne capture pas la géométrie globale du paysage de perte dans un espace de 110 M dimensions.

La formulation de keskar2017large s'applique à des perturbations dans toutes les directions :

$$\phi_{x,f}(\epsilon) = \frac{\max_{y \in \mathcal{C}_\epsilon(x)} f(A^+ y) - f(Ax)}{1 + f(Ax)} \times 100 \tag{11}$$

où $\mathcal{C}_\epsilon = \{y : \|y - x\|_\infty \leq \epsilon(|x| + 1)\}$. La mesure 1D utilisée ici est une approximation de cette définition complète.

5 Discussion

Q : Comment le weight_decay et le dropout affectent-ils la généralisation de CamemBERT fine-tuné sur Allociné ?

Weight Decay. Dans ce protocole, l'effet du weight decay est **marginal** pour des valeurs modérées. La plage $[10^{-5}, 10^{-3}]$ produit des performances quasi-identiques. Deux interprétations complémentaires :

1. *Pré-normalisation implicite* : CamemBERT est pré-entraîné avec des poids de petites normes (régularisation implicite via le pré-entraînement sur OSCAR). Le fine-tuning ne les perturbe que marginalement, rendant le weight decay additionnel peu discriminant.
2. *Régime few-shot* : Avec seulement 1 000 exemples d'entraînement, l'overfitting est contenu par la capacité limitée des données, indépendamment du WD.

Dropout. Le dropout est le régulateur **le plus impactant**. Les résultats confirment :

— **dropout = 0,1** est optimal : compromis bruit/signal idéal pour les transformers de 100 M+ paramètres.

— **dropout = 0,3** est destructeur : le bruit stochastique massif (30% des activations annulées à chaque forward pass) empêche la convergence sur les 2–3 premières époques, créant un gradient de mise à jour incohérent.

— **dropout = 0,0** : légèrement sur-apprenant mais toléré grâce au sous-échantillonnage et à l'early stopping.

5.1 Apport de l'optimisation bayésienne

L'optimisation Optuna/TPE apporte une valeur ajoutée décisive par l'exploration du **learning rate**, absent du protocole grid search :

— La LR optimale ($\approx 5 \times 10^{-5}$) est **2,5× supérieure** à la valeur de référence (2×10^{-5}). Elle permet une adaptation plus rapide sur le sous-ensemble limité.

— L'interaction **lr × weight_decay** est capturée par le TPE : un LR plus élevé nécessite un WD modéré (10^{-3}) pour contrôler la magnitude des gradients.

— 20 trials suffisent pour explorer un espace hyperparamétrique $4 \times 3 \times \infty$ grâce à l'échantillonnage intelligent TPE.

5.2 Analyse du loss landscape-limites et enseignements

L'analyse 1D du paysage de perte confirme que CamemBERT converge vers des régions relativement plates du paysage (Sharpness < 0.3), ce qui est cohérent avec la bonne généralisation observée. Le résultat contre-intuitif (dropout=0.1 $\rightarrow$ sharpness élevée) met en évidence :

1. La **dimensionnalité** du problème : dans un espace de 110 M dimensions, une direction 1D capture moins de 1% de la variance géométrique.

2. Le rôle du **dropout comme régularisateur de trajectoire** : le dropout force le modèle à explorer un ensemble plus large de configurations pendant l'entraînement, résultant en un minimum peut-être moins plat dans la direction testée, mais plus robuste aux perturbations réelles de la distribution des données.

5.3 Limites et perspectives

Limites.

— **Taille du sous-ensemble** : 1 000 exemples d'entraînement est représentatif pour une étude de régularisation mais insuffisant pour les performances absolues. Les résultats sur le dataset complet (160 000) pourraient différer.

— **Variabilité** : chaque configuration n'est testée qu'avec une seule graine. Un écart-type sur $k = 5$ runs permettrait des tests statistiques formels (test de Wilcoxon, intervalles de confiance bootstrap).

— **Analyse landscape 1D** : l'extension à une analyse 2D (deux directions orthogonales, Li et al. 2018) fournirait une représentation plus complète de la géométrie locale.

Perspectives.

— **SAM (Sharpness-Aware Minimization)** foret2021sam : optimizer qui minimise explicitement la sharpness, potentiellement plus efficace que le couple weight_decay + dropout.

— **LoRA (Low-Rank Adaptation)** hu2022lora : fine-tuning paramétrique-efficient qui réduit le nombre de paramètres entraînables, limitant intrinsèquement l'espace de sur-apprentissage.

— **Évaluation out-of-domain** : tester la généralisation sur des critiques d'autres plateformes (IMDb, SensCritique) pour évaluer la robustesse à la distribution shift.

— **Analyse du gradient** : mesurer la norme du gradient par couche pour quantifier l'impact du dropout sur la propagation du signal d'erreur à travers les 12 couches Transformer.

Conclusion

Ce travail démontre que le fine-tuning de CamemBERT sur Allociné est **robuste à la régularisation** dans une plage raisonnable d'hyperparamètres. Le protocole P02 révèle que le dropout (valeur critique = 0,1) est le levier de régularisation le plus impactant, tandis que le weight decay joue un rôle de second ordre grâce à la normalisation implicite du pré-entraînement.

L'optimisation bayésienne (Optuna/TPE) apporte le gain décisif en explorant l'interaction lr $\times$ régularisation, atteignant **F1-test = 0,9600** soit une **réduction de 40% du taux d'erreur** par rapport à la baseline. L'analyse du loss landscape confirme que les modèles convergent vers des minima relativement plats, mais met en évidence les limites de la mesure 1D de sharpness pour des espaces paramétriques de très haute dimension.

Ces résultats ont des implications pratiques directes pour le déploiement de modèles NLP en contexte marketing : la simplicité de la configuration optimale (dropout=0.1 standard, weight decay modéré) facilite la reproductibilité et le déploiement sans hyperparamétrage intensif.